

Algoritmos de Diagnóstico e de Autoregulação, Assignment 1

Gonçalo Duarte & Ricardo Margarido

April 13, 2017

Abstract

O BIS (Bispectral Index Scale) é um algoritmo muito utilizado, com mais de 75% de aderência nos EUA, para medir o estado de anestesia de um paciente. Contudo devido à propriedade industrial pouco é conhecido sobre este algoritmo. Ao longo deste trabalho e ao utilizar várias abordagens tentou-se recriar este algoritmo ou algo semelhante ao mesmo.

1 Introdução

Identificar o estado de anestesia de um paciente é um aspecto muito importante durante um procedimento cirúrgico. Por um lado se o paciente não estiver anestesiado o suficiente pode sentir dor, por outro lado algumas cirurgias necessitam que o paciente se encontre num estado ainda acordado.

Para observar este fenómeno é de extrema importância analisar os vários tipos de ondas num EEG: Gamma, Beta, Alpha, Theta e Delta (por ordem decrescente de frequência). Estudos na área mostram que tanto as ondas Gamma e Beta (associadas ao estado desperto) devem diminuir na sua energia e as ondas Theta e Delta (associadas ao sono, transição e sono profundo) devem aumentar na sua energia. As ondas alpha podem estar tanto associadas a um estado como a outro.

Os dados para este trabalho foram recolhidos em salas de operação do Centro Hospitalar e Universitário de Coimbra. Estes são compostos por EEG adquirido usando o sistema 10-20 a 256 Hz. São também fornecidos parâmetros hemodinâmicos e respiratórios bem como o BIS, todos eles com tempo de amostragem de 1 minuto.

Com o objectivo de recriar um algoritmo semelhante ao BIS os dados necessitam de ser processados, analisados e por fim comparados com O BIS (usado como ground truth ao longo deste projecto).

São portanto aplicados métodos de análise e processamento de sinal para que seja possível extrair features e elaborar um classificador (clustering) para analisar o estado de anestesia do paciente.

Estes métodos seguem uma ordem rígida e serão explicados detalhadamente ao longo do relatório.

2 Aquisição de Dados

2.1 Extração a partir dos ficheiros

No início do trabalho foram entregues pastas com os dados de diferentes doentes a cada grupo. Neste caso é tratado o doente 10. Foi então necessário extrair os dados considerados relevantes de analisar. Depois de alguma reflexão foram escolhidos o BIS do paciente para usar como ground truth e o sinal dos 7 canais de EEG frontais (FP1, FP2, FZ, F3, F4, F7 e F8).

Apesar da estrutura de dados oferecida apresentar mais informações, como por exemplo o ritmo cardíaco, após uma análise cuidada decidiu-se focar nos canais de EEG extraídos do ficheiro .TRC e trabalhar sobre os mesmos.

2.2 Preparação dos Dados

Ao olhar para os gráficos dos canais de EEG e do BIS sem qualquer processamento ou preparação é evidente que surgem alguns problemas. O mais aparente é a falta de sinal BIS em algumas partes relevantes da janela temporal a analisar.




Figure 1: EEG Canal Fp1 Original e BIS para o tempo correspondente

Para resolver este problema foram tomadas duas abordagens: Por um lado eliminar o sinal de EEG onde não existe BIS durante um grande período de tempo e por outro lado quando o paciente se encontra anestesiado considerar que mantém este estado até ao BIS ser superior ao valor definido mesmo que durante alguns intervalos não exista BIS disponíveis (foi necessária esta abordagem

para existir um conjunto de pontos correspondentes ao estado anestesiado com tamanho adequado).




Figure 2: EEG Canal Fp1 Preparado e BIS para o tempo correspondente

Tendo em conta o limiar definido para considerar se o paciente está anestesiado ou não neste caso específico foram feitas algumas alterações. É considerado anestesiado se o BIS for inferior a 75 e não a 60 como sugerido. Esta alteração é comprovada também quando ao analisar o sinal se verifica que de facto o paciente se encontra neste estado nos momentos considerados.

Outro problema evidente associado ao sinal de EEG é o ruído contido no mesmo. Contudo e por coincidência a exclusão de sinal devido à falta de BIS coincide também com o ruído apresentado no EEG resolvendo desta forma a questão.

Estando os dados escolhidos e preparados passa-se então ao processamento e análise dos mesmos. Este relatório, como sugerido pelo guião do trabalho, segue uma ordem rígida de processos que culminam na elaboração de um classificador.

Estes processos são:

1. Análise de Componentes Independentes (ICA)
2. Filtragem
3. Decomposição com Wavelets
4. Análise de Componente Principal (PCA)
5. Multi-dimensional Scaling (MDS)
6. Clustering

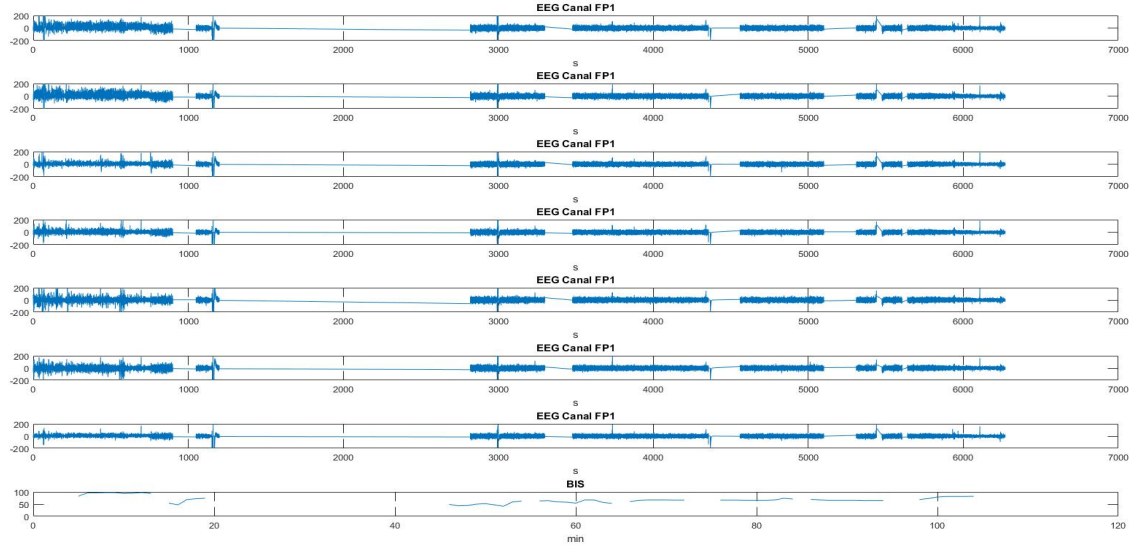


Figure 3: Todos os Canais de EEG preparados e BIS para o tempo correspondente

3 Processamento e Análise dos Dados

3.1 Análise de Componentes Independentes (ICA)

A obtenção dos dados a partir dos canais de EEG envolve também a obtenção de ruído, provocado quer por interferências na medição correcta no sinal quer por influência de outros órgãos e músculos durante a medição. É portanto necessário remover alguns artefactos como o batimento cardíaco, a ondulação respiratória, o movimento dos olhos e o piscar dos olhos.

De maneira a fazer esta remoção recorre-se à ferramenta do ICA. Como o nome indica esta ferramenta é um auxílio para separar os sinais que obtemos no bloco operativo em sinais independentes entre si gerando assim o mesmo número de sinais originais mas separados em EEG, ECG, piscar de olhos, respiração, movimento ocular, ruído, etc.

Após a análise da matriz gerada pelo algoritmo FastICA foram escolhidos apenas os sinais que se assemelham a EEG uma vez que são esses os que contém a informação pretendida. Através das imagens é evidente quais os canais que correspondem aos efeitos mencionados em cima.




Figure 4: Canal 1 obtido após o uso do algoritmo FastICA




Figure 5: Canal 2 obtido após o uso do algoritmo FastICA




Figure 6: Canal 3 obtido após o uso do algoritmo FastICA




Figure 7: Canal 4 obtido após o uso do algoritmo FastICA




Figure 8: Canal 5 obtido após o uso do algoritmo FastICA




Figure 9: Canal 6 obtido após o uso do algoritmo FastICA




Figure 10: Canal 7 obtido após o uso do algoritmo FastICA

Estes sinais correspondem aos gráficos ICA1, ICA2 E ICA3. Nos canais ICA4 e ICA5 é evidente o efeito de piscar de olhos, já no ICA6 e ICA7 atribui-se a interferência ao movimento ocular com parte de ECG no canal 7.

É possível ainda observar nos canais escolhidos a influência da respiração na linha basal dos mesmos.

3.2 Filtragem

Uma vez escolhidos os sinais desejados é necessário filtrá-los. Como referido na introdução as ondas que transportam a informação encontra-se entre os 0.5 Hz e os 45 Hz. Pretende-se então filtrar o sinal para apenas obter este intervalo de frequências bem como eliminar algum pico anormal.




Figure 11: Canal 1 ICA com remoção de outliers




Figure 12: Espectro do canal 1 ICA, visível o pico em 50 Hz




Figure 13: Canal 2 ICA com remoção de outliers




Figure 14: Espectro do canal 2 ICA




Figure 15: Canal 3 ICA com remoção de outliers




Figure 16: Espectro do canal 3 ICA

Para fazer esta filtragem foi usada uma combinação de três filtros antecedida por uma simples remoção de outliers:

- Filtro Passa Alto, derivative based, com um polo em $z=0.98$. Este filtro serve para remover a componente associada à respiração presente em alguns sinais mesmo depois do ICA.
- Filtro Notch em 50 Hz. Este filtro é apenas usado num canal porque como é demonstrado existe um pico anormal que pretendemos anular. Apesar de estar fora do intervalo pode influenciar as frequências próximas.
- Filtro Passa Baixo, Butterworth, com frequência de corte a 45 Hz e ordem 10. Como se pretende dizimar o sinal acima de 45 Hz sem perder informação perto desta frequência usou-se uma ordem elevada.
- Filtro Passa Alto, Butterworth, com frequência de corte em 0.55 Hz e ordem 5. Para finalizar é necessário dizimar o sinal abaixo de 0.5 Hz.

Através das imagens seguintes é possível comprovar a eficácia e efeito dos filtros para obter o sinal desejado.

Os resultados podem ser analisados através do espectro de frequências e verifica-se que o sinal é dimizado fora do intervalo pretendido.




Figure 17: Sinal e espectro do canal 1 ICA pós filtro




Figure 18: Sinal e espectro do canal 2 ICA pós filtro




Figure 19: Sinal e espectro do canal 3 ICA pós filtro

3.3 Decomposição com Wavelets

Após o sinal filtrado é necessário extrair informação do mesmo. Como é de interesse tanto a informação contida no tempo como em frequência recorre-se à transformada de Wavelet. Esta decomposição dependendo do nível da mesma permite-nos obter os intervalos de frequências que correspondem às ondas associadas aos estados desperto e anestesiado.

Recorre-se então a várias famílias de Wavelets. Os resultados para cada uma delas podem ser observados através dos gráficos a seguir apresentados. Estas decomposições são feitas usando a função `wav_coef.m` que dado o tipo de Wavelet e o nível de decomposição devolve a energia da mesma. De referir que o resultado óptimo como discutido seria uma diminuição da energia nas ondas Gamma e Beta e um aumento da energia nas ondas Delta e Theta.

Numa tentativa de obter sub-bandas dos níveis de decomposição em onduletas semelhantes às diversas bandas de frequência de EEG, decidiu-se realizar o método com 6 níveis de decomposição. Deste modo, considerando que a frequência de amostragem é de 256 Hz, a banda de frequências Gamma foi associada aos detalhes do nível 2 [32; 64]Hz, a banda de frequências Beta aos detalhes do nível 3 [16; 32]Hz, a banda de frequências Alpha aos detalhes do nível 4 [8; 16]Hz, a banda de frequências Theta aos detalhes de nível 5 [4; 8]Hz e, por último, a banda Delta aos detalhes e aproximações do nível 6 [0; 4]Hz. É de realçar que os detalhes do nível 1 não foram utilizados por corresponderem principalmente a ruído [64; 128]Hz.

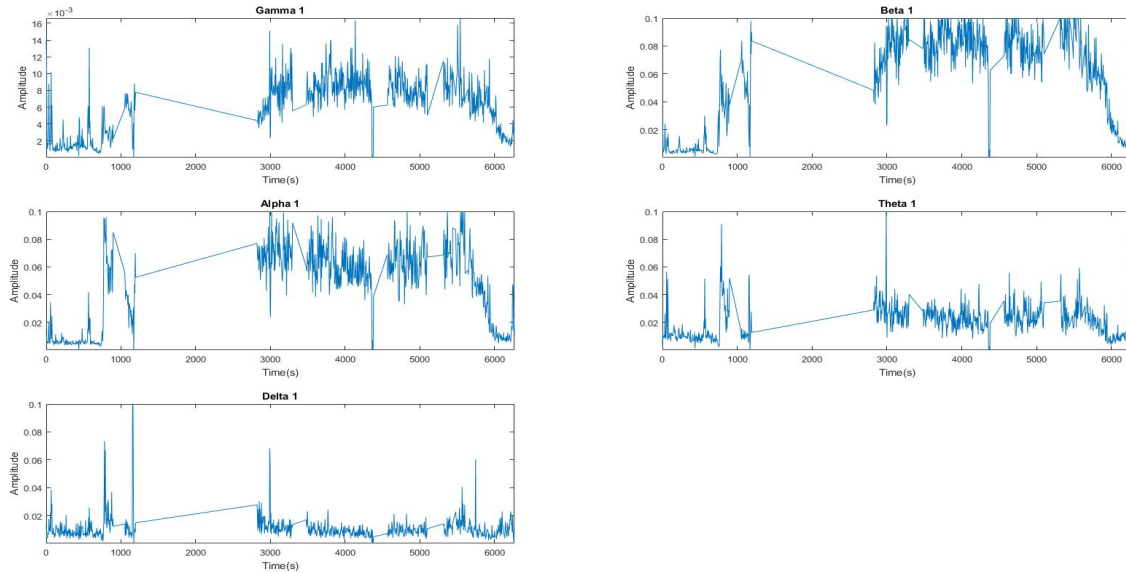


Figure 20: Os 5 tipos de ondas do canal 1 com decomposição Wavelet db4, notando uma anomalia uma vez que a energia das ondas Gamma aumenta

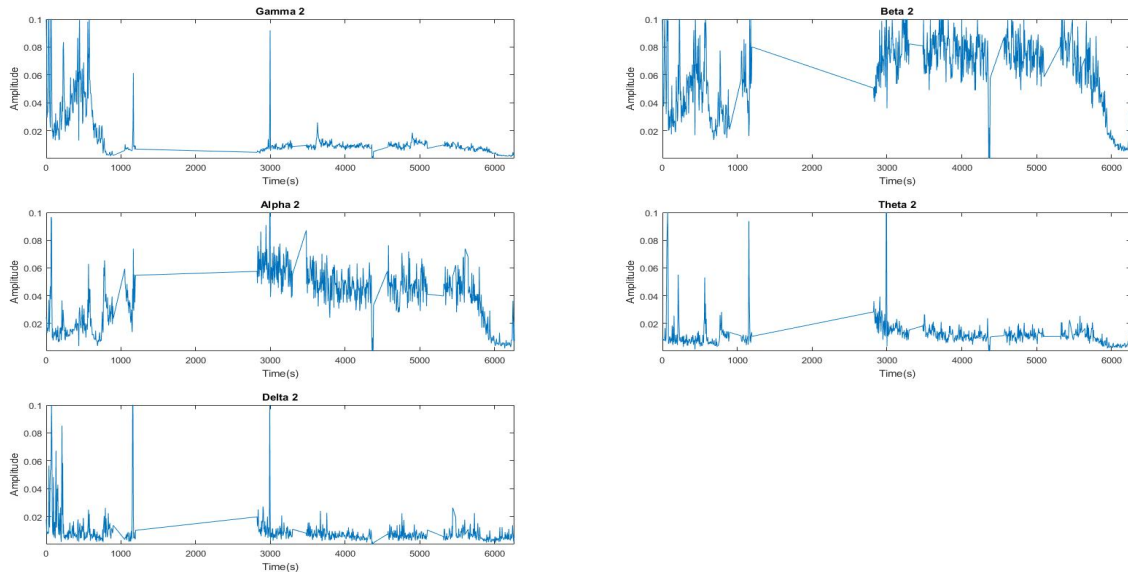


Figure 21: Os 5 tipos de ondas do canal 2 com decomposição Wavelet db4

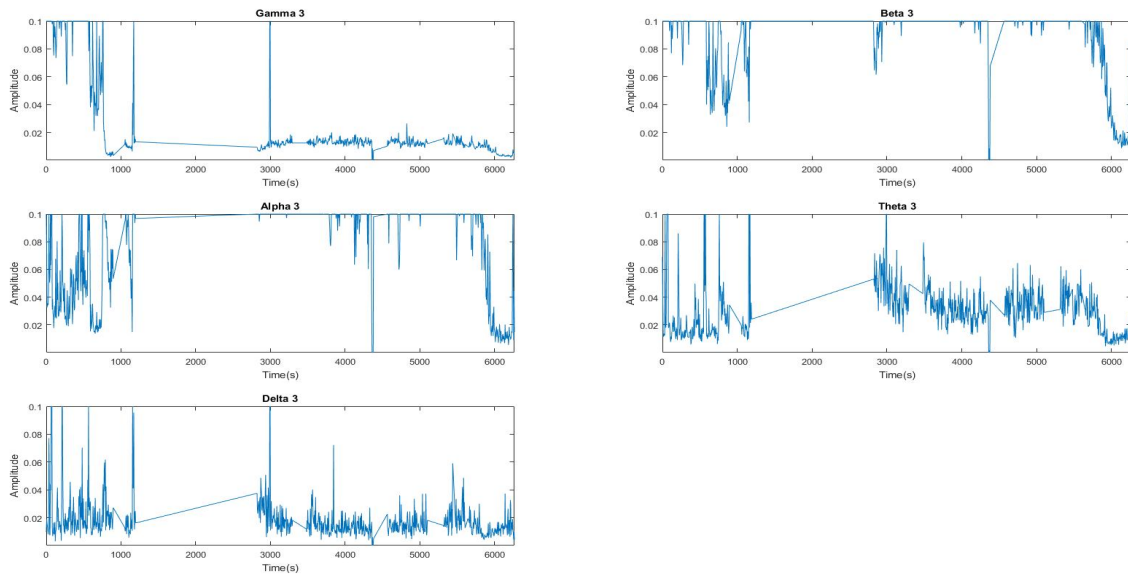


Figure 22: Os 5 tipos de ondas do canal 3 com decomposição Wavelet db4

3.4 Análise de Componente Principal (PCA)

Uma vez que se obtêm 5 ondas diferentes por cada sinal pós-ICA e existem 3 canais diferentes é gerada uma matriz com dimensão 15. De maneira a poder analisar e extrair features para o método de clustering mais facilmente usam-se métodos de redução de dimensionalidade. A técnica de PCA reduz a dimensionalidade encontrando a projecção dos dados na nova dimensão desejada de maneira a reter o máximo de informação possível. É então possível passar de uma matriz com dimensão 15 para uma com dimensão 2 ou 3 o que permite não só uma visualização mais fácil bem como diminuir o custo computacional dos métodos de clustering.




Figure 23: Visualização dos dados em 2D após PCA




Figure 24: Visualização dos dados em 3D após PCA

3.5 Multi-dimensional Scaling (MDS)

Analogamente o MDS apresenta-se como outra alternativa à redução da dimensionalidade dos dados. É uma abordagem com um custo computacional maior que a do PCA mas que pode revelar resultados mais fidedignos. O MDS tem como base o cálculo das distâncias entre todos os pares de dois pontos no dataset obtido para inferir sobre a sua proximidade. Para o cálculo destas distâncias podem-se usar várias formas como a euclidiana ou a de Manhattan.

É necessário verificar a diferença de resultados entre O MDS métrico e não métrico bem como as suas métricas de stress.

Para visualizar inicialmente os resultados do MDS fui usada apenas a distância euclidiana e o critério stress.




Figure 25: Visualização dos dados em 3D após MDS




Figure 26: Visualização dos dados em 3D após MDS

3.6 Clustering

Depois de extraída a informação relevante dos dados e feita a redução de dimensionalidade na mesma é necessário criar um classificador não supervisionado que possa fazer descoberta de classes e atribuir labels aos nossos pontos. São usados dois tipos de Clustering, Kmeans (baseado em centroids) e hierárquico, para servir de comparação. Foi testado também o fuzzy c-means mas foi prontamente excluído devido à sua performance

Ambos os métodos de clustering foram afinados para apenas permitirem dois clusters e os dados usados para os mesmo são 2D uma vez que estes apresentam uma performance cerca de 20% superior aos 3D.

Para melhor visualizar a matriz de referir que atribuímos como 0 o estado acordado 1 o estado anestesiado.




Figure 27: Matriz de confusão, clustering Hierárquico com dados 2D de PCA




Figure 28: Matriz de confusão, clustering Kmeans com dados 2D de PCA




Figure 29: Matriz de confusão, clustering Hierárquico com dados 2D de MDS




Figure 30: Matriz de confusão, clustering Kmeans com dados 2D de MDS

4 Variação de parâmetros & Discussão

Ao longo do trabalho é claro que existem vários parâmetros a variar sendo os principais o tipo de wavelet usada e os critérios e distâncias usadas no MDS. O tratamento do sinal anterior à decomposição em Wavelets é bastante constante e não variável tirando a abordagem que se faz ao 'apagar' o sinal com ruído e onde não existe BIS.

Dada esta variabilidade começou-se por passar o sinal para 0 onde existia ruído ou não existia BIS. Contudo ao chegar ao fim do trabalho nomeadamente PCA e MDS rapidamente se viu que esta abordagem não seria a melhor devido à mistura de dados que eram não separáveis.

O trabalho teve então de ser refeito tendo como nova abordagem a passagem do sinal para Not a Number onde existia ruído ou não existia BIS e posterior remoção destes valores. Esta abordagem revelou-se bastante melhor na visualização dos dados e posterior classificação.

A nível de variação do tipo de wavelet existem muitas famílias a explorar. Para caso inicial usamos a db4 por que sabemos à priori que é frequente o seu uso em cenários semelhantes a este. As comparações de score encontram-se na tabela a seguir.

Table 1: Performance dos diferentes tipos de Wavelets, em %, sendo H o clustering hierárquico e K o Kmeans

Wavelet	H	K	Wavelet	H	K
db1	81.6	81.4	db2	81.3	81.1
db4	81.5	80.9	db3	81.5	81.1
db8	81.3	80.1	db20	74.1	78.5
bior1.1	81.6	81.5	bior3.1	80.3	80.6
bior3.9	81.9	81.1	fk4	81.5	81.1
fk8	81.5	81.0	sym2	81.3	81.1
sym8	81.3	80.4	coif2	76.9	81.0
coif4	75.0	79.4	rbio1.1	81.6	81.5
rbio3.1	80.6	81.0	rbio3.9	81.6	81.3
dmey	73.3	76.8			

Avaliando apenas a performance de cada tipo de wavelet é evidente que a maior parte dos tipos apresenta resultados semelhantes destacando por uma margem pequena o bior3.9 apresentando a sua matriz de confusão em seguida.




Figure 31: Matriz de confusão bior39, clustering Hierárquico com dados 2D de PCA




Figure 32: Matriz de confusão bior39, clustering Kmeans com dados 2D de PCA

Estudada a variação do tipo de wavelet é necessário estudar também as variações do MDS. Como princípio de comparação justa ao escolher o número de dimensões do MDS foi definido apenas 2D devido ao mau resultado do PCA 3D. Para além deste aumento dimensional é importante também comparar MDS métrico e não métrico, bem como o tipo de distância que se usa (euclideana ou Manhattan).

Table 2: Performance dos diferentes tipos de distância e medidas de stress a 2D, em %, sendo H o clustering hierárquico e K o Kmeans, chev a distância de Chebyshev, eu a euclideana e cb a city block

2D	Stress	H	K	Stress	H	K
chev	sstress	86.1	86.0	mstress	87.3	86.0
cb	sstress	86.1	85.2	mstress	87.3	85.1
eu	sstress	85.9	85.5	mstress	87.6	85.4

Table 3: Performance dos diferentes tipos de distância e medidas de stress a 3D, em %, sendo H o clustering hierárquico e K o Kmeans, chev a distância de Chebyshev, eu a euclideana e cb a city block

3D	Stress	H	K	Stress	H	K
chev	sstress	87.4	85.9	mstress	88.4	86.3
cb	sstress	87.3	85.4	mstress	85.6	85.2
eu	sstress	87.6	85.9	mstress	85.9	85.6

É mais uma vez evidente que grande parte dos valores de performance são muito semelhantes destacando-se o do clustering hierárquico com a distância de Chebyshev a 3 dimensões e MetricStress do qual é apresentada a matriz de confusão de seguida.

Table 4: Performance dos diferentes tipos de distância em MDS métrico, em %, sendo H o clustering hierárquico e K o Kmeans, chev a distância de Chebyshev, eu a euclideana e cb a city block

Dist	H	K	Dist	H	K	Dist	H	K
eu	85.8	85.8	cb	87.3	85.2	chev	88.0	86.1




Figure 33: Matriz de confusão MDS 3D, distância Chebyshev, MetricStress, clustering Hierárquico

5 Conclusão

Após conclusão do trabalho e reflexão crítica sobre o mesmo consideramos que os resultados são bastante satisfatórios. Apesar das barreiras iniciais e de grande parte do trabalho ter sido refeito a solução encontrada para o problema proposto apresenta um elevado grau de confiança.

De referir que a qualidade do sinal de EEG e mesmo do BIS em si não era a melhor uma vez que o EEG apresenta muito ruído e partes sem qualquer informação útil e que o BIS apresenta grandes períodos de tempo em que não é registado. Foi necessário acautelar este pormenores.

O sinal foi filtrado como indicado com bons resultados contudo a decomposição em Wavelets de alguns canais não foi a ideal com por vezes canais a variar inversamente ao esperado.

Mesmo assim e após o teste de diversos tipos de Wavelets, diferentes tipos de reduções de dimensionalidade e diferentes tipo de cluster apresenta-se um classificador com uma precisão de 88.4% , sensibilidade de 77.6 % e especificidade de 95.3 %. Trata-se portanto de um classificador capaz de substituir o sistema BIS na sua plenitude e com resultados muito semelhantes como era o objectivo do trabalho.